3 - Regresi?n logistica multi-clase y redes neuronales

December 13, 2018

En esta práctica resolveremos la problemática de reconocimiento de carácteres utilizando el dataset MNIST con dos modelizaciones diferentes, regresión logística multiclase y redes neuronales pre-entrenadas.

1 Regresión logística multi-clase

1.1 Visualización de los datos



1.2 Vectorización de la regresión logística

La implementación de la función sigmoide sigue la siguiente expresión:

$$g(z) = \frac{1}{1 + e^{-z}}$$

siendo

$$h_{\theta}(x^{(i)}) = g(\theta^T x^{(i)})$$

1.2.1 Vectorización de la función de coste

Función coste

$$J(\theta) = \frac{1}{m} ((\log(g(X\theta))^{T}(-y) - (\log(1 - g(X\theta))^{T}(1 - y)))$$

1.2.2 Vectorización del gradiente

Gradiente

$$\frac{\delta J(\theta)}{\delta \theta_j} = \frac{1}{m} X^T (g(X\theta) - y)$$

1.2.3 Cálculo de la versión regularizada

Función coste

$$J(\theta) = \frac{1}{m} ((\log(g(X\theta))^{T}(-y) - (\log(1 - g(X\theta))^{T}(1 - y)) + \frac{\lambda}{2m} \sum_{j=1}^{n} \theta_{j}^{2}$$

Gradiente

$$\frac{\delta J(\theta)}{\delta \theta_i} = \frac{1}{m} X^T (g(X\theta) - y) + \frac{\lambda}{m} \theta_j$$

```
In [29]: def cost_function_opt(th, x, y, reg):
             def fun(z):
                 return 1/(1 + np.e**(-z))
             h = fun(np.dot(x, th))
             J = np.sum(-y * np.log(h) - (1 - y) * np.log(1 - h)) / len(X)
             J += (reg / (2 * len(X))) * (np.sum(th ** 2))
             return J
         def cost_gradient_opt(th, x, y, reg):
             def fun(z):
                 return 1/(1 + np.e**(-z))
             cg = (1/len(x))*x.T.dot(fun(np.dot(x, th)) - y) + th*reg/len(X)
             return cg
1.2.4 Clasificación de uno frente a todos
In [11]: import scipy.optimize as opt
In [27]: def oneVsAll(th, X, y, num_labels, reg):
             th_ret = []
             for i in range(1, num_labels + 1):
                 result = opt.fmin_tnc(func=cost_function_opt, x0=th,
                                        fprime=cost_gradient_opt,
                                        args=(X, (y == i)*1, reg))
                 th_ret.append(result[0])
             return th_ret
In [17]: th_zeros = np.zeros(len(X[0]))
         reg = 0.1
In [30]: th_train = oneVsAll(th_zeros, X, np.ravel(y), len(np.unique(y)), reg)
         print(len(th_train), len(th_train[0]))
10 401
In [15]: print ("Coste óptimo obtenido con scipy.optimize.fmin_tnc():\n\t{}".
                format([cost_function_opt(th_train[i], X, y, reg)
                        for i in range(0,len(th_train))]))
Coste óptimo obtenido con scipy.optimize.fmin_tnc():
        [array([-20.11266776]), array([-18.46294437]), array([-18.45871036]), array([-18.4629999
```

1.3 Evaluación de la regresión logística multiclase

Porcentaje de aciertos sobre los casos de entrenamiento:96.5%

2 Red neuronal pre-entrenada

La red neuronal que tratamos en este ejercicio tiene tres capas estructuradas de la siguiente forma: - 400 unidades en la primera capa (*input layer*) - 25 unidades en la segunda capa (*hidden layer*) - 10 unidades en la tercera capa (*output layer*)

```
In [18]: weights = loadmat('datasets/ex3weights.mat')
         theta_layer1, theta_layer2 = weights['Theta1'], weights['Theta2']
         print('theta_layer1.shape:{};\ntheta_layer2.shape:{};'.
               format(theta_layer1.shape, theta_layer2.shape))
theta_layer1.shape:(25, 401);
theta_layer2.shape:(10, 26);
In [19]: def model_evaluation_nn(X, y, th, fun):
             num_hits = 0
             for index, x in enumerate(X):
                 output_layer1 = np.array([fun(th[0][i].dot(x.T)) for i in range(0,len(th[0]))])
                 output_layer1 = np.insert(output_layer1, 0, 1)
                 output_layer2 = np.array([fun(th[1][i].dot(output_layer1)) for i in range(0,len
                 probability_per_classifier = output_layer2
                 best_probability_prediction_index = np.argmax(probability_per_classifier)
                 prediction = best_probability_prediction_index+1
                 if(prediction == y[index]):
                     num\_hits += 1
```

return (num_hits/len(X))*100

Autores: Iván Fernández Mena y Alberto Pastor Moreno

Porcentaje de aciertos sobre los casos de entrenamiento:97.52%